Mohamed Tahiri

Ingénieur IA | Agents LLM, RAG, évaluation

Miami, États-Unis | me@mohamedtahiri.com | mohamedtahiri.com | linkedin.com/in/moha-tah | github.com/moha-tah

Ingénieur IA qui met en production des systèmes à base de LLM et les mesure : agents, recherche documentaire, évaluation, CI et infrastructure. Seul ingénieur d'un assistant IA utilisé dans une filiale du groupe Air France-KLM.

Expérience professionnelle

Ingénieur IA (VIE) | Groupe Air France-KLM, Miami, États-Unis — mars 2026 – févr. 2027

- Conception et mise en production, seul, d'un agent IA qui répond aux questions de maintenance aéronautique et de l'entreprise en citant ses sources (Claude ; 11 outils en lecture seule dont recherche hybride, recherches exactes, text-to-SQL ; photo et voix ; anglais, français, espagnol). En service depuis mars 2026 et étendu à toute l'entreprise ; la DRH en a fait le point d'entrée des questions RH sur l'intranet.
- Indexation de plus de 1,3 million de fragments (historique de maintenance et intranet mis à jour toutes les heures, manuels techniques) : recherche hybride dense et sparse dans Qdrant, embeddings Voyage AI, reranking.
- Évaluations de la recherche et des réponses (77 requêtes annotées ; 33 questions réelles, LLM-as-judge) comparant 5 modèles d'embedding et 5 rerankers : le reranking porte le nDCG@10 de 0,68 à 0,84, et un changement de modèle a réduit la latence médiane de 8,5 à 5,6 s et le coût par question de 18 % à qualité égale.
- Fiabilité et coût maîtrisés : plus de 2 600 tests (seuil de couverture à 99 %), analyses de sécurité en CI, Terraform (111 ressources), Ansible, alertes Sentry et CloudWatch, prompt caching.
- Plugin Claude Code qui transforme un court questionnaire en vidéos de formation et formations interactives aux couleurs de l'entreprise, pour des équipes non techniques : script, synthèse vocale locale, rendu Remotion.

Stagiaire ingénieur logiciel, backend et data | Napta, Paris — sept. 2024 – févr. 2025

- Pipelines ETL Python/Airflow (API, SFTP, bases de données, CSV) vers PostgreSQL, sur des millions de lignes.
- Bot GitLab-Slack qui a réduit de 50 % le délai de revue des merge requests, de l'idée à l'adoption par l'équipe.
- Amélioration d'outils Flask internes, de la CI/CD et du produit React/Next.js (équipe de sept ingénieurs seniors).

Formateur en algorithmique, bénévole | UT'Code, Compiègne — févr. 2023 – févr. 2024

- Formation d'étudiants à l'algorithmique ; 6e sur 70 équipes (210 participants) à un concours de programmation.

Projets

Plateforme de découverte de cours | web, iOS et Android — 2024 – aujourd'hui

- Premier contributeur (plus de 1 100 commits, équipe de 15) : backend NestJS sur PostgreSQL (Supabase), authentification et permissions, synchronisation transactionnelle de la recherche Algolia, et l'essentiel de l'infrastructure Terraform/Terragrunt (trois environnements, détection quotidienne des dérives).

SDK et intégrations pour une plateforme associative d'horaires | Python, TypeScript — 2023 – aujourd'hui

- Spécification OpenAPI 3.1, vérifiée chaque nuit contre l'API réelle, et générateurs de SDK open source typés Python et TypeScript : couverture de 100 %, environ 3 300 téléchargements par mois sur PyPI et npm.
- Reprise et refonte de la skill Alexa (de JavaScript à TypeScript, AWS Lambda, DynamoDB, EventBridge ; 7 locales) ; auteur principal de l'intégration Home Assistant (118 installations ; proposée au cœur, en revue).

Expérimentation d'agent autonome | Claude Code, Python — 2026

- Agent Claude Code qui cherche, construit, teste et publie des outils de données web, avec validation humaine de toute dépense : 7 outils en ligne sur l'Apify Store, 117 tests, un serveur MCP inscrit au registre MCP officiel.

Formation

Université de technologie de Compiègne (UTC), Alliance Sorbonne Université | France — 2022 – 2026

Diplôme d'ingénieur (grade de master) en génie informatique, filière ingénierie des systèmes d'information.
Cours : machine learning, deep learning, systèmes distribués, bases de données, algorithmique, statistiques.

Classe préparatoire MPSI | Lycée Charlemagne, Paris — 2021 – 2022

Compétences

IA et LLM : API Claude, agents et tool use, RAG, recherche hybride, reranking, embeddings, Qdrant, Voyage AI, évaluation (métriques de recherche, LLM-as-judge), prompt caching, MCP, Claude Code, PyTorch
Langages : Python, TypeScript, SQL, Go, Java
Backend et data : NestJS, Next.js, React, Chainlit, Flask, Airflow, PostgreSQL, DuckDB, Supabase, Algolia
Infrastructure : Docker, Terraform, Ansible, AWS, GCP, GitHub Actions, GitLab CI, Sentry, pytest, Playwright
Langues : français (langue maternelle), anglais (courant, TOEIC 985/990)